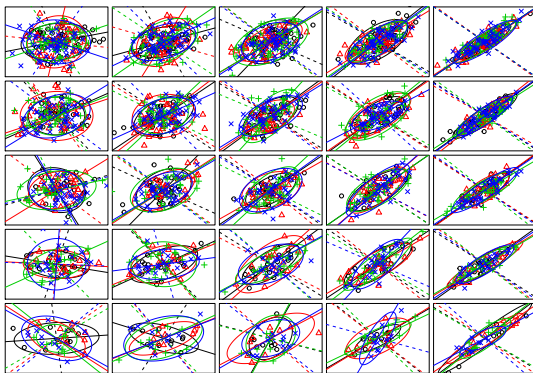


# Estatística Multivariada

Slides de apoio às aulas







Faculdade de Ciências e Tecnologia  
Universidade Nova de Lisboa  
2018/19

## Aula 7

## Análise em Componentes Principais

- A Análise em Componentes Principais (ACP) é uma técnica exploratória de análise de dados multivariados não estruturados.
- A existência de um número de variáveis demasiadamente elevado coloca, em regra, problemas no processo de análise dos dados (*Curse of dimensionality*)
- *Objetivo geral*: Agrupar as variáveis observadas num número de novas variáveis, designadas por *componentes principais*, inferior ao número de variáveis inicial, perdendo o mínimo de informação estatística (variabilidade) possível.
- *Objetivos específicos*:
  - 1 redução da dimensionalidade (representação da maior quantidade possível de informação estatística usando um menor número de variáveis);
  - 2 transformação de variáveis correlacionadas em variáveis independentes e constituição de dimensões mais homogêneas (dentro)/heterogêneas (entre) do que as iniciais.

- O objetivo principal de uma ACP é então o de reduzir a dimensão  $p$  da matriz inicial  $\mathbf{X}_{n \times p}$  à *mais interessante* matriz de todas as que têm menor dimensão do que a inicial ( $\mathbf{Y}_{n \times q}$ , com  $q < p$ ).
- A solução consiste em encontrar um conjunto de vetores (ortogonais) que definam a direção de projeção de  $\mathbf{X}$  *mais interessante* num subespaço de dimensão inferior à inicial.
- Do ponto de vista estatístico pode entender-se como *mais interessante* a direção de projeção que permite preservar a maior informação/variabilidade possível e, ao mesmo tempo, permite minimizar as distâncias entre os pontos observados e os pontos projetados.
- A projeção que minimiza o erro (perda de informação) é a definida pela direção de maior variabilidade.
- Ou seja, supondo uma nuvem de pontos elipsóide, o que se pretende é encontrar os eixos "naturais" dessa nuvem com origem em  $\bar{\mathbf{x}}$ , o que é feito centrando o vetor  $\mathbf{x}$  e rodando os eixos.



## O que são componentes principais?

- Chamam-se **componentes principais** (amostrais) às  $p$  combinações lineares  $\mathbf{y} = (y_1, y_2, \dots, y_p)$  das  $p$  variáveis originais  $\mathbf{x} = (x_1, x_2, \dots, x_p)$ :

$$y_1 = a_{11}x_1 + a_{12}x_2 + \dots + a_{1p}x_p$$

$$y_2 = a_{21}x_1 + a_{22}x_2 + \dots + a_{2p}x_p$$

...

$$y_p = a_{p1}x_1 + a_{p2}x_2 + \dots + a_{pp}x_p$$

onde  $a_{kj}$  ( $k, j = 1, \dots, p$ ) são coeficientes desconhecidos (a estimar).

- A matriz

$$\mathbf{A} = \begin{bmatrix} a_{11} & \dots & a_{1p} \\ a_{21} & \dots & a_{2p} \\ \vdots & \vdots & \vdots \\ a_{q1} & \dots & a_{qp} \end{bmatrix}$$

é designada por matriz de *saturações*, ou matriz dos *pesos fatoriais* (*PC loadings*).

- Assim,

$$\mathbf{y} = a_{k1}x_1 + a_{k2}x_2 + \dots + a_{kp}x_p = \sum_{j=1}^p a_{kj}x_j = \mathbf{a}'_k \mathbf{x}$$

representa as  $k$  ( $k = 1, \dots, p$ ) componentes principais, com média  $\mathbf{a}'_k \bar{\mathbf{x}}$  e variância  $\mathbf{a}'_k \mathbf{S} \mathbf{a}_k$

## Como se obtêm as componentes principais?

- A obtenção das  $k$  CP tem início com a determinação da combinação linear com variância máxima correspondente à primeira componente principal

$$\mathbf{a}'_1 \mathbf{x}$$

- Assim, pretende-se estimar o vetor  $\mathbf{a}_1$  de dimensão  $p$  que maximiza

$$\text{var}(\mathbf{a}'_1 \mathbf{x}) = \mathbf{a}'_1 \mathbf{S} \mathbf{a}_1$$

- O máximo da forma quadrática  $\mathbf{a}'_1 \mathbf{S} \mathbf{a}_1$  restrita a  $\mathbf{a}'_1 \mathbf{a}_1 = 1$  (normalizado) é dado pelo maior valor próprio da matriz  $\mathbf{S}$ ,  $\ell_1$ , com vetor próprio correspondente  $\mathbf{e}_1$ , isto é, o máximo de  $\mathbf{a}'_1 \mathbf{S} \mathbf{a}_1$  ocorre para

$$\hat{\mathbf{a}}_1 = \mathbf{e}_1$$

- A sucessivas CP,  $\mathbf{a}'_k \mathbf{x}$  com  $k \geq 2$ , são determinadas por maximização de  $\mathbf{a}'_k \mathbf{S} \mathbf{a}_k$  sujeita à ausência de correlação com  $\mathbf{a}'_{k-1} \mathbf{x}$ , equivalendo à determinação dos pares  $(\ell_k, \mathbf{e}_k)$  ( $k = 1, \dots, p$ )



# Como se obtêm as componentes principais?

- Em resumo, os vetores  $\mathbf{a}_k$  são estimados sucessivamente de modo a satisfazer as seguintes condições:

- As variâncias das componentes têm valores decrescentes para  $k = 1, \dots, p$ , i.e.,  $\text{var}(\mathbf{a}'_1 \mathbf{x}) \geq \text{var}(\mathbf{a}'_2 \mathbf{x}) \geq \dots \geq \text{var}(\mathbf{a}'_p \mathbf{x})$  correspondentes aos valores próprios  $\ell_k$ , da matriz de covariâncias  $\mathbf{S}$ , isto é:

$$\ell_1 = \text{var}(\mathbf{a}'_1 \mathbf{x})$$

$$\ell_2 = \text{var}(\mathbf{a}'_2 \mathbf{x})$$

...

$$\ell_p = \text{var}(\mathbf{a}'_p \mathbf{x})$$

- A covariância entre quaisquer duas componentes  $k$  e  $k'$  é nula, i.e.,  $\mathbf{a}'_{k'} \mathbf{S} \mathbf{a}_k = 0$ ,  $k \neq k'$ ;
- Para cada componente, os vetores  $\mathbf{a}_k$  possuem norma unitária:

$$a_{k1}^2 + a_{k2}^2 + \dots + a_{kp}^2 = 1, \quad (k = 1, \dots, p)$$

sendo estimados pelos  $k$  vetores próprios de  $\mathbf{S}$ .

# Decomposição da variância total

- Seja  $\mathbf{A} = (\mathbf{a}_1, \dots, \mathbf{a}_p)$  estimada pelos de vetores próprios  $(\mathbf{e}_1, \dots, \mathbf{e}_p)$  e  $\mathbf{y}$  o vetor de componentes principais  $\mathbf{y} = \mathbf{a}'\mathbf{x}$ , então a matriz de covariâncias de  $\mathbf{y}$  é dada por

$$\text{var}(\mathbf{y}) = \mathbf{A}'\mathbf{S}\mathbf{A} = \begin{bmatrix} \ell_1 & 0 & \dots & 0 \\ \vdots & \vdots & \vdots & \vdots \\ 0 & 0 & \dots & \ell_p \end{bmatrix}$$

- As variâncias das componentes principais são estimadas pelos valores próprios  $\ell_1, \dots, \ell_p$  sendo a sua soma o traço de  $\mathbf{A}'\mathbf{S}\mathbf{A}$

$$\sum_{k=1}^p \text{var}(y_k) = \sum_{k=1}^p \ell_k = \text{tr}(\mathbf{A}'\mathbf{S}\mathbf{A})$$

- Por outro lado,  $\text{tr}(\mathbf{A}'\mathbf{S}\mathbf{A}) = \text{tr}(\mathbf{S}\mathbf{A}\mathbf{A}') = \text{tr}(\mathbf{S}) = \sum_{j=1}^p \text{var}(x_j)$
- Logo

$$\sum_{j=1}^p \text{var}(x_j) = \sum_{k=1}^p \text{var}(y_k)$$

- Assim, a proporção da variância total original explicada por cada uma das CP é dada por

$$\frac{\ell_k}{\sum_{k=1}^p \ell_k}$$

e as primeiras  $m$  CP explicam uma proporção cumulativa de  $\frac{\sum_{k=1}^m \ell_k}{\sum_{k=1}^p \ell_k}$

## Exemplo 1

Seja  $\mathbf{X} \in \mathbb{R}^{20 \times 2}$  a matriz de 20 valores observados para duas variáveis  $(x_1, x_2)$ . Considere-se a matriz de covariâncias

$$\mathbf{S} = \begin{bmatrix} 2.459 & 1.019 \\ 1.019 & 2.472 \end{bmatrix}$$

Valores próprios de  $\mathbf{S}$ :  $\ell_1 = 3.484 \wedge \ell_2 = 1.447$

Vetores próprios de  $\mathbf{S}$ :  $\mathbf{e}'_1 = (0.705, 0.709)$  e  $\mathbf{e}_2 = (-0.709, 0.705)$ .

Código R:

```
> round(S,3)

      [,1] [,2]
[1,] 2.459 1.019
[2,] 1.019 2.472

> round(eigen(S)$values,3)

[1] 3.484 1.447

> round(eigen(S)$vectors,3)

      [,1] [,2]
[1,] 0.705 -0.709
[2,] 0.709  0.705
```

Sendo as CP dadas por

$$y_1 = 0.705x_1 + 0.709x_2$$

$$y_2 = -0.709x_1 + 0.705x_2$$

explicando, respetivamente, 71% e 20% da variabilidade original.

Código R:

```
> round(eigen(S)$values[1]/sum(eigen(S)$values),2)
[1] 0.71
> round(eigen(S)$values[2]/sum(eigen(S)$values),2)
[1] 0.29
```

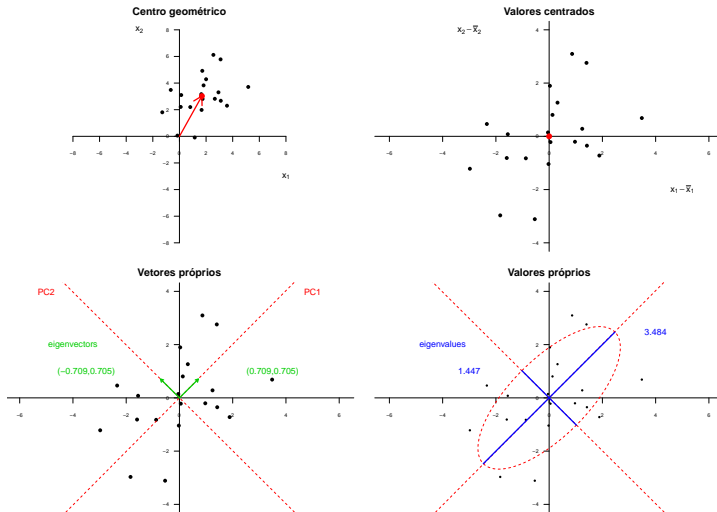
- Frequentemente, consideram-se os vetores centrados  $\mathbf{x}_c = \mathbf{x} - \bar{\mathbf{x}}$  na obtenção das componentes principais
- A transformação de  $\mathbf{x}$  em  $\mathbf{x}_c$  apenas altera a média de cada variável, que passa a ser zero
- Geometricamente, o centro de gravidade da nuvem de  $n$  passa a ser a origem, ou seja, há uma translação do centro de gravidade:

$$(x_1, \dots, x_p) \rightarrow (0, \dots, 0)$$

- Com esta transformação as componentes principais passam a ter as seguintes características finais:

- 1  $\bar{y}_k = 0$
- 2  $\text{var}(y_k) = \ell_k$
- 3  $\text{cov}(y_k, y_{k'}) = 0$
- 4  $\text{var}(y_1) \geq \text{var}(y_2) \geq \dots \geq \text{var}(y_k) \geq 0$
- 5  $\sum_{k=1}^p \text{var}(y_k) = \text{tr}(\mathbf{S})$
- 6  $\prod_{k=1}^p \text{var}(y_k) = |\mathbf{S}|$

# Exemplo (continuação)



- Em muitos casos as variáveis possuem unidades de medida distintas e/ou diferentes graus de heterogeneidade.
- Variáveis com diferentes unidades de medida, não podem ser incluídas conjuntamente na análise porque não são diretamente comparáveis.
- Por outro lado, variáveis mais heterogêneas (com maior variância) têm mais peso na constituição das CP do que as variáveis mais homogêneas e são, por isso, integradas nas primeiras CP (distorcendo a solução final).
- Para ultrapassar este problema é prática comum proceder à padronização das variáveis, i.e., determinar  $z_{ij} = \frac{x_{ij} - \bar{x}_j}{s_j}$ , ( $i = 1, \dots, n$ ;  $j = 1, \dots, p$ ), sendo a matriz inicial **X** substituída pela matriz **Z** com elementos  $z_{ij}$ .
- No caso das variáveis estarem padronizadas a matriz **S** é igual à matriz das correlações, **R**.
- Quando as variáveis não estão padronizadas, a solução encontrada partindo de **S** ou de **R** não é a mesma → diferentes vetores próprios
- A maioria dos autores recomenda a padronização prévia das variáveis para que a solução não seja distorcida pela ordem de grandeza e/ou heterogeneidade das variáveis (já que a variância é influenciada pela magnitude dos valores observados).

## Exemplo (continuação)

Considere-se a matriz  $\mathbf{X}_{20 \times 2}$  e a respetiva matriz de correlações

$$\mathbf{R} = \begin{bmatrix} 1.000 & 0.413 \\ 0.413 & 1.000 \end{bmatrix}$$

Valores próprios de  $\mathbf{R}$ :  $\ell_1 = 1.413 \wedge \ell_2 = 0.587$

Vetores próprios de  $\mathbf{R}$ :  $\mathbf{e}'_1 = (0.707, 0.707)$  e  $\mathbf{e}'_2 = (-0.707, 0.707)$

Código R:

```
> R<-cor(X)
> round(R,3)

      [,1] [,2]
[1,] 1.000 0.413
[2,] 0.413 1.000

> round(eigen(R)$values,3)

[1] 1.413 0.587

> round(eigen(R)$vectors,3)

      [,1] [,2]
[1,] 0.707 -0.707
[2,] 0.707  0.707
```



- A soma das variâncias das  $p$  CP é igual à soma da variância das  $p$  variáveis originais dada por  $\sum_{k=1}^p \ell_k$ . Quando as variáveis são padronizadas  $\sum_{k=1}^p \ell_k = p$  (porque a variância de cada variável é 1).
- A *proporção da variância total* explicada pela componente  $k$  é dada por

$$\frac{\ell_k}{\sum_{k=1}^p \ell_k} = \frac{\ell_k}{\text{tr}(\mathbf{S})}$$

- Quando as variáveis são padronizadas esta proporção é dada por  $\frac{\ell_k}{p}$  ( $k = 1, \dots, p$ ).
- A correlação entre a  $j$ -ésima variável e a  $k$ -ésima CP  $y_k = \mathbf{a}'_k \mathbf{x}$  é dada por

$$r_{(x_j, y_k)} = \sqrt{\frac{\ell_k}{s_{jj}}} \mathbf{e}_{kj}$$

- Onde, em variáveis padronizadas,

$$r_{(z_j, y_k)} = \sqrt{\ell_k} \mathbf{e}_{kj}$$

sendo os valores destas correlações particularmente úteis na interpretação das CP.

- O principal objetivo em muitas aplicações da ACP é substituir as  $p$  variáveis originais por um número de novas variáveis  $q \ll p$  reterendo a maior quantidade de informação estatística possível. É crucial saber quão pequeno pode ser  $q$  sem que a perda de informação seja "relevante".
- Existem vários critérios de decisão quanto ao número de componentes a reter:
  - ❶ **Percentagem de variabilidade explicada:** Reter um número  $q$  tal que a percentagem cumulativa de variabilidade explicada pelas  $q$  CP não seja inferior a um valor de corte fixado *a priori*. Tipicamente este valor situa-se entre 70 e 90%.
  - ❷ **Critério de Kaiser:** Segundo este critério retêm-se as componentes cujo valor próprio é superior à média dos valores próprios  $\sum_{k=1}^p \ell_i / p$ .  
Em variáveis padronizadas, uma componente com valor próprio inferior a 1 indica que não retém a informação (variabilidade) equivalente a uma das variáveis originais (com variância 1, por estarem padronizadas). Assim, de acordo com este critério, em variáveis padronizadas, são retidas as CP com valor próprio superior a 1.
  - ❸ **Scree plot:** Um *scree plot* relaciona os valores próprios com as CP ordenadas por ordem de grandeza dos respetivos valores próprios. O número de CP é ditado pelo ponto onde a linha desenhada diminui acentuadamente de inclinação, tornando-se tendencialmente horizontal.
  - ❹ **Teste aos valores próprios:** Reter as primeiras  $q$  componentes se

$$H_{0q} : \lambda_{q+1} = \dots = \lambda_p$$

não for rejeitada (abordado na secção de inferência sobre valores próprios)

## Exemplo 2

Os dados do ficheiro "data8.xlsx" foram recolhidos como parte de um estudo preliminar de uma possível ligação entre design de capacete em jogadores de futebol americano e lesões no pescoço. Foram amostrados 60 sujeitos de três grupos tendo sido realizadas seis medições:

- WDIM = largura da cabeça (maior dimensão);
- CIRCUM = circunferência da cabeça;
- FBEYE = medição da frente para trás ao nível dos olhos;
- EYEHD = medição do olho ao topo da cabeça;
- EARHD = medida da orelha ao topo da cabeça;
- JAW = largura da mandíbula.

Faça uma análise em componentes principais dos dados do ficheiro.

### Código R:

```
> dados8<-as.data.frame(readxl::read_xlsx("./Datasets/data8.xlsx", col_names = TRUE))
> dados<-scale(dados8,center = TRUE,scale = TRUE)
> S<-var(dados)
> round(S,3)
```

	WDIM	CIRCUM	FBEYE	EYEHD	EARHD	JAW
WDIM	1.000	0.608	0.361	0.060	0.252	0.605
CIRCUM	0.608	1.000	0.733	0.336	0.090	0.410
FBEYE	0.361	0.733	1.000	0.014	-0.028	0.311
EYEHD	0.060	0.336	0.014	1.000	0.297	-0.079
EARHD	0.252	0.090	-0.028	0.297	1.000	-0.090
JAW	0.605	0.410	0.311	-0.079	-0.090	1.000

- Em regra nos procedimentos multivariados  $n > p$ . Contudo, hoje em dia, fruto da crescente capacidade computacional de registo e armazenamento de informação são frequentes as situações onde  $n < p$  (e.g. expressão de genes).
- Nestes casos nada impede que se realize uma ACP - *Sparse ACP*. Contudo, o número de CP fica limitado pelo  $\min\{n, p\}$ , ou seja, se  $n < p$  poderão ser definidas apenas  $n$  CP para explicar toda a variabilidade original.
- A ACP baseia-se na existência de padrões de associação estatística entre as variáveis originais, isto é na existência de correlações (pelo menos uma parte delas) elevadas.
- Antes de efetuar uma ACP deve por isso analisar-se a **matriz das correlações**

- Porém, correlações bivariadas elevadas não são condição suficiente para garantir a existência de variáveis latentes. A existência de um padrão latente que simultaneamente afeta várias variáveis não é detectada por este tipo de correlações. Para detectar este tipo de estrutura é aconselhável a análise da **matriz de correlações parciais**
- As correlações parciais são medidas de associação linear bivariada, retirando o efeito de todas as restantes variáveis em análise. Para  $p = 3$

$$r_{x,y|z} = \frac{r_{xy} - r_{yz}r_{xz}}{\sqrt{1 - r_{yz}^2} \sqrt{1 - r_{xz}^2}}$$

- Os seus valores quantificam a contribuição unitária, não comum, de cada variável para a variância total. Quanto maior for a variância comum, menor o valor das correlações parciais. Assim, quanto menores forem as correlações parciais, mais adequada será a ACP.

- **Teste de Esfericidade (Mauchly):** Este procedimento permite testar se a matriz de correlações é igual à matriz identidade:

$$H_0 : \rho = \begin{bmatrix} 1 & \rho_{12} & \dots & \rho_{1p} \\ \rho_{21} & 1 & \dots & \rho_{2p} \\ \vdots & \vdots & \ddots & \vdots \\ \rho_{p1} & \rho_{p2} & \dots & 1 \end{bmatrix} = \begin{bmatrix} 1 & 0 & \dots & 0 \\ 0 & 1 & \dots & 0 \\ \vdots & \vdots & \ddots & \vdots \\ 0 & 0 & \dots & 1 \end{bmatrix}$$

isto é, se as variáveis são independentes e têm a mesma variância, equivalente a

$$H_0 : \Sigma = \sigma^2 \mathbf{I}$$

Qual a importância deste procedimento?

- A aplicação deste teste supõe a existência de normalidade multivariada, i.e.,  $\mathbf{x} \sim N_p(\mu, \Sigma)$ . Sob  $H_0$ , a estatística do teste ( $U^*$ )

$$U^* = -\left(n - 1 - \frac{2p^2 + p + 2}{6p}\right) \ln U$$

com  $U = \Lambda^{2/n}$  e  $\Lambda = \frac{|\mathbf{S}|^{n/2}}{(tr(\mathbf{S})/p)^{np/2}}$ , ou seja,

$$U = \frac{p^p |\mathbf{S}|}{(tr(\mathbf{S}))^p}$$

tem distribuição aproximada  $\chi^2_{\frac{1}{2}p(p+1)-1}$

- A interpretação das CP é frequentemente feita atendendo aos *loadings* (elementos dos vetores próprios)
- Tal como vimos anteriormente a correlação ente a  $k$ -ésima CP e a  $j$ -ésima variável original (dados standartizados) é dada por:  $r_{kj} = \sqrt{\ell_k} e_{kj}$
- Assim, valores absolutos elevados indicam uma "identificação" das CP com essas variáveis, devendo a interpretação das CP basear-se nessas variáveis
- Regras usuais para considerar as correlações "elevadas":
  - 1  $r_{k\cdot}^2 \geq \ell_k / \sum_{k=1}^p \ell_k$  ou  $r_{k\cdot}^2 \geq \ell_k / p$  (var. standartizadas)
  - 2  $|r_{kj}^2| \geq 0.5$  |  $r_{kj}^2 \geq 0.25$
- Como interpretar  $r_{kj}^2$ ? Proporção de variabilidade  $j$ -ésima variável original explicada pela  $k$ -ésima CP
- Advertência: É frequente ignorar variáveis com correlações (ou loadings) próximas de zero. Isto pode induzir em erro, e convém utilizar informação complementar para validar as interpretações baseadas nos coeficientes!

- Até aqui a ACP foi abordada numa perspectiva estritamente exploratória, descritiva. A utilização desta técnica com um objectivo inferencial obriga a considerar as **distribuições amostrais dos valores e vetores próprios** da matriz de covariâncias.

- Notação:

- ❶ **População:**

$\lambda' = (\lambda_1, \dots, \lambda_p) \rightarrow$  vetor de valores próprios de  $\Sigma$ , com elementos  $\lambda_k$  ( $k = 1, \dots, p$ )

$\alpha_k$  ( $k = 1, \dots, p$ )  $\rightarrow$  vetores próprios de  $\Sigma$ , com elementos  $\alpha_{kj}$

- ❷ **Amostra:**

$\ell' = (\ell_1, \dots, \ell_p) \rightarrow$  vetor de valores próprios de  $S$ , com elementos  $\ell_k$  ( $k = 1, \dots, p$ )  $\mathbf{a}_k$

( $k = 1, \dots, p$ )  $\rightarrow$  vetores próprios de  $S$ , com elementos  $a_{kj}$

- Numa população normal multivariada de dimensão  $p$ , i.e.,  $\mathbf{x} \sim N_p(\boldsymbol{\mu}, \Sigma)$  os EMV dos valores próprios (todos positivos e distintos) e vetores próprios de  $\Sigma$  são os valores e vetores próprios de  $S$ , i.e.,

$$\hat{\lambda}_k = \ell_k$$

$$\hat{\alpha}_k = \mathbf{a}_k$$



- ❶ **Valores próprios:**  $\ell_k$  tem distribuição de probabilidade assintótica normal multivariada (dimensão  $p$ ) com

- Valor médio:  $E(\ell_k) = \lambda_k$
- Variância:  $Var(\ell_k) = \frac{2\lambda_k^2}{n-1}$   
ou seja,

$$\ell_k \stackrel{a}{\sim} N\left(\lambda_k, \frac{2\lambda_k^2}{n-1}\right)$$

- ❷ **Vetores próprios:**  $\mathbf{a}_k$  tem distribuição de probabilidade assintótica normal multivariada (dimensão  $p$ ) com

- Valor médio:  $E(\mathbf{a}_k) = \boldsymbol{\alpha}_k$
- Variância:

$$Var(\mathbf{a}_k) = \frac{\lambda_k}{n-1} \sum_{j=1}^p \frac{\lambda_j}{(\lambda_j - \lambda_k)^2} \boldsymbol{\alpha}_j \boldsymbol{\alpha}_j' \quad (j \neq k)$$

ou seja,

$$\mathbf{a}_k \stackrel{a}{\sim} N_p\left(\boldsymbol{\alpha}_k, \frac{\lambda_k}{n-1} \sum_{j=1}^p \frac{\lambda_j}{(\lambda_j - \lambda_k)^2} \boldsymbol{\alpha}_j \boldsymbol{\alpha}_j'\right)$$

- Para  $n$  suficientemente grande:

❶  $\ell_k$  e  $\mathbf{a}_k$  são variáveis aleatórias independentes;

❷ Distribuição assintótica centrada e reduzida de  $\ell_k$ :

$$\sqrt{n-1}(\ell_k - \lambda_k) \xrightarrow[n \rightarrow \infty]{d} N(0, 2\lambda_k^2)$$

Dado que, pelo Teorema de Slutsky,  $\lambda_k/\ell_k \xrightarrow[n \rightarrow \infty]{p} 1$ ,

$$\frac{\sqrt{n-1}(\ell_k - \lambda_k)}{\ell_k \sqrt{2}} \xrightarrow[n \rightarrow \infty]{d} N(0, 1)$$

❸ Distribuição assintótica centrada e reduzida de  $\mathbf{a}_k$ :

$$\sqrt{n-1}(\mathbf{a}_k - \boldsymbol{\alpha}_k) \xrightarrow[n \rightarrow \infty]{d} N(0, \mathbf{T}_k)$$

com  $\mathbf{T}_k = \lambda_k \sum_{j=1}^p \frac{\lambda_j}{(\lambda_j - \lambda_k)^2} \boldsymbol{\alpha}_j \boldsymbol{\alpha}_j' (j \neq k)$ . Dado que, pelo Teorema de Slutsky,

$$\boldsymbol{\alpha}_j / \mathbf{a}_j \xrightarrow[n \rightarrow \infty]{p} 1,$$

$$\frac{\sqrt{n-1}(\mathbf{a}_k - \boldsymbol{\alpha}_k)}{\left( \ell_k \sum_{j=1}^p \frac{\ell_j}{(\ell_j - \ell_k)^2} \mathbf{a}_j \mathbf{a}_j' \right)^{1/2}} \xrightarrow[n \rightarrow \infty]{d} N(0, 1)$$

- Considerando que  $\sqrt{n-1}(\ell_k - \lambda_k) \stackrel{a}{\sim} N(0, 2\lambda_k^2)$ , o intervalo de confiança assintótico para  $\lambda_k$  a  $(1 - \delta) \times 100$  é dado por

$$\left( \frac{\ell_k}{1 + z_{1-\delta/2} \sqrt{2/(n-1)}}, \frac{\ell_k}{1 - z_{1-\delta/2} \sqrt{2/(n-1)}} \right)$$

- Tendo em conta o Teorema de Slutsky, o intervalo de confiança assintótico para  $\lambda_k$  a  $(1 - \delta) \times 100$  pode aproximar-se por

$$\left( \ell_k - z_{1-\delta/2} \ell_k \sqrt{\frac{2}{n-1}}, \ell_k + z_{1-\delta/2} \ell_k \sqrt{\frac{2}{n-1}} \right)$$

$z_{1-\delta/2}$  representa o quantil de probabilidade  $1 - \delta/2$  da distribuição normal padrão.

- No caso dos vetores próprios, mostra-se que (Mardia et al., 1979, p. 233 e Joliffe, 2002, p. 52) que (baseado no comportamento assintótico das distâncias de Mahalanobis)

$$(n-1)(\mathbf{a}_k - \boldsymbol{\alpha}_k)' \mathbf{W} (\mathbf{a}_k - \boldsymbol{\alpha}_k) \stackrel{a}{\sim} \chi_{p-1}^2$$

com

$$\mathbf{W} = \ell_k \mathbf{S}^{-1} + \ell_k^{-1} \mathbf{S} - 2\mathbf{I}_p$$

- Sendo a região de confiança para  $\boldsymbol{\alpha}_k$  a  $(1 - \delta) \times 100$  é dada por

$$(n-1)\boldsymbol{\alpha}_k' (\ell_k \mathbf{S}^{-1} + \ell_k^{-1} \mathbf{S} - 2\mathbf{I}_p) \boldsymbol{\alpha}_k \leq \chi_{p-1}^2 (1 - \delta)$$

- Para testar  $H_0 : \lambda_k = \lambda_{k0}$  tem-se a estatística adequada

$$\sqrt{\frac{n-1}{2}} \frac{\ell_k - \lambda_{k0}}{\lambda_{k0}}$$

com distribuição assintótica  $N(0, 1)$ , sob  $H_0$

- Para testar a existência de esfericidade parcial, i.e.,  $H_0 : \lambda_{q+1} = \dots = \lambda_p$  tem-se a estatística adequada

$$Q = \left[ \frac{\prod_{k=q+1}^p \ell_k}{\left( \sum_{k=q+1}^p \ell_k / (p - q) \right)^{p-q}} \right]^{n/2}$$

com  $-2 \ln Q \curvearrowright \chi^2_\nu$  e  $\nu = \frac{1}{2}(p - q + 2)(p - q - 1)$ , sob  $H_0$

- Para testar  $H_0 : \alpha_k = \alpha_{k0}$  tem-se a estatística adequada

$$(n-1)\alpha'_{k0} \left( \ell_k \mathbf{S}^{-1} + \ell_k^{-1} \mathbf{S} - 2\mathbf{I}_p \right) \alpha_{k0}$$

e distribuição assintótica  $\chi^2_{p-1}$ , sob  $H_0$